



Instituto Tecnológico de Estudios Superiores Monterrey

Campus Querétaro

[TC3002B – Desarrollo de aplicaciones avanzadas de ciencias computacionales]

Actividad 2 ML.

Profesores:

Benjamín Valdés Aguirre

Presentan:

Dafne Fernández Hernández

A01369230

Fecha de entrega: 29/04/2025

Clasificación Automática del Alzheimer Usando MobileNetV2

Documentación Técnica del Proyecto

1. Introducción

El Alzheimer es una enfermedad neurodegenerativa progresiva que afecta la memoria y otras funciones cognitivas. La detección temprana es clave para retrasar su avance y mejorar la calidad de vida del paciente. Este proyecto tiene como objetivo construir un sistema automatizado para la clasificación de imágenes de resonancia magnética (MRI) cerebral utilizando redes neuronales convolucionales (CNN), en particular mediante el modelo MobileNetV2.

El proyecto implementa un enfoque basado en aprendizaje profundo para clasificar imágenes cerebrales en cuatro categorías clínicas: NonDemented, VeryMildDemented, MildDemented y ModerateDemented. Se parte de una implementación básica de transferencia de aprendizaje con MobileNetV2 congelado, y posteriormente se realizan mejoras progresivas en cuanto a la arquitectura, optimización, y manejo del desbalance de clases, documentando detalladamente los resultados en cada iteración.

2. Selección y Preparación del Dataset

2.1 Selección del Conjunto de Datos

En una primera etapa, se utilizó un dataset reducido (~4000 imágenes) con una distribución desbalanceada de clases, lo cual generó resultados deficientes, particularmente en las clases menos representadas. Esto evidenció la necesidad de un conjunto de datos más robusto para una clasificación eficaz.

En la segunda fase, se adoptó un dataset significativamente más grande (más de 33,000 imágenes) que incluye imágenes aumentadas para balancear las clases. Este dataset fue generado a partir de la base “Alzheimer MRI Dataset” y procesado para garantizar una distribución equitativa entre las categorías.

2.2 Preprocesamiento

- **Redimensionado:** Todas las imágenes fueron redimensionadas a 180x180 píxeles para ajustarse al tamaño de entrada del modelo MobileNetV2.
- **Normalización:** Se aplicó el preprocesamiento de MobileNetV2 (normalización según los pesos preentrenados de ImageNet).
- **Conversión de etiquetas:** Se utilizó codificación one-hot (label_mode='categorical') para compatibilidad con la capa de salida del modelo.
- **Segmentación del dataset:** Se dividió el conjunto de datos en 70% para entrenamiento, 15% para

validación y 15% para prueba, usando `image_dataset_from_directory` de TensorFlow.

3. Implementación del Modelo

3.1 Modelo Base: MobileNetV2

El modelo seleccionado para la tarea fue MobileNetV2, una red convolucional eficiente basada en bloques de conexiones residuales invertidas y cuellos de botella lineales, diseñada específicamente para aplicaciones en dispositivos con recursos limitados. MobileNetV2 ha demostrado un buen rendimiento en tareas de clasificación médica, como se respalda en la literatura científica.

Referencia:

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. arXiv preprint arXiv:1801.04381.

3.2 Arquitectura del Modelo

- **Base convolucional:** MobileNetV2 preentrenado en ImageNet (pesos congelados).
- **Capas adicionales:**
 - GlobalAveragePooling2D
 - Dense(256, activation='relu')
 - Dropout(0.3)

- Dense(4, activation='softmax')

Esta arquitectura permite mantener la eficiencia del modelo original, al mismo tiempo que introduce capacidad de ajuste a la tarea específica mediante capas densas personalizadas.

3.3 Compilación del Modelo

- **Función de pérdida:** Categorical Crossentropy
 - **Métrica de evaluación:** Accuracy
 - **Optimizador (fase 1):** SGD con tasa de aprendizaje 0.001
 - **Optimizador (fase 2):** Adam con tasa de aprendizaje 0.0001, tras observar mejor desempeño en tareas con datasets complejos y no lineales.
-

4. Evaluación Inicial del Modelo

4.1 Resultados con Dataset Inicial

Métrica Valor


Accuracy 54.34%

Precision 0.51


Recall 0.58

F1-score 0.51

Matriz de Confusión



Curvas de Precisión y Pérdida



Observaciones:

- El modelo mostraba un fuerte sesgo hacia la clase mayoritaria (NonDemented).
- Las clases ModerateDemented y MildDemented presentaban métricas prácticamente nulas.
- El bajo número de ejemplos y la ausencia de fine-tuning limitaban severamente el aprendizaje.
- No cuenta con alta precisión de predicción



5. Refinamiento del Modelo

5.1 Cambios Realizados

- **Ampliación del dataset:** Se integró un dataset con más de 33,000 imágenes, asegurando un número considerable de ejemplos por clase.
- **Optimización avanzada:** Se reemplazó SGD por el optimizador

Adam, el cual mostró mejor convergencia.

- **Regularización:** Se mantuvo Dropout(0.3) para prevenir overfitting.
- **Balanceo de clases:** Se introdujo el parámetro class_weight en el entrenamiento, ajustando el peso de cada clase inversamente proporcional a su frecuencia.
- **Evaluación robusta:** Se incluyeron matrices de confusión, reporte de clasificación detallado y análisis de métricas macro y ponderadas.


5.2 Resultados Finales

Evaluación en conjunto de prueba (5099 muestras):


Clase	Precisión	Recall	F1-score
MildDemented	0.76	0.70	0.73
ModerateDemented	0.99	0.98	0.99
NonDemented	0.66	0.75	0.70
VeryMildDemented	0.51	0.48	0.49
Métrica global	Valor		
Accuracy	70.96 %		

Clase	Precisión	Recall	F1-score
Precision promedio	0.71		
Recall promedio	0.71		
F1-score promedio	0.71		

Matriz de Confusión



Curvas de Precisión y Pérdidas



Interpretación:

- Se observa un aumento del 16% en la precisión general respecto a la versión inicial.
- La introducción de class_weight fue determinante para mejorar la

sensibilidad en clases menos representadas.

- El modelo alcanza un rendimiento competitivo para aplicaciones clínicas exploratorias.
- Mayor precisión en predicciones



6. Visualización de Resultados

6.1 Matriz de Confusión

La matriz de confusión permitió observar el desempeño específico en cada clase, destacando mejoras en la clasificación de

clases previamente ignoradas por el modelo.

6.2 Curvas de Entrenamiento

Las curvas de pérdida y precisión en entrenamiento y validación indicaron un entrenamiento estable, sin señales de sobreajuste, en parte gracias al uso de regularización y aumento de datos.

7. Conclusiones

Este proyecto demuestra cómo un modelo ligero como MobileNetV2 puede ser adaptado exitosamente para tareas de clasificación médica, siempre que se acompañe de un adecuado preprocesamiento, balanceo de clases, y ajuste de hiperparámetros.

Puntos clave:

- El dataset inicial era insuficiente. Su ampliación fue esencial para que el modelo aprendiera representaciones discriminativas.
- El uso del optimizador Adam y `class_weight` fue determinante para la mejora en métricas.
- MobileNetV2 demostró ser una base eficiente para tareas de clasificación multiclase en el dominio biomédico.

8. Referencias

- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. arXiv preprint arXiv:1801.04381. <https://arxiv.org/abs/1801.04381>
- Gupta, R., et al. (2022). *Deep Learning for Alzheimer's Disease Diagnosis: A Survey*. Artificial Intelligence in Medicine. <https://www.sciencedirect.com/science/article/abs/pii/S0933365722000975>
- Kalra, A., et al. (2024). *A Proficient Approach for the Classification of Alzheimer's Disease Using a Hybridization of Machine Learning and Deep Learning*. Scientific Reports. <https://www.nature.com/articles/s41598-024-81563-z>
- Ilyas, S., et al. (2024). *A Comparative Study of Deep Learning Techniques for Alzheimer's Disease Detection in Medical Radiography*. IJCSNS. <https://www.researchgate.net/publication/381002805>